

Datorlaboration 6

Josef Wilzén

24 september 2026

Allmänt

Datorlaborationerna kräver att ni har R och Rstudio installerat.

- Kodmanual: [länk](#)
- **ISL**: An Introduction to Statistical Learning,
 - Boken: [länk](#)
 - R-kod till labbar: [länk](#)
 - Dataset: [länk](#) och [länk](#)
- **IDM**: Introduction to Data Mining
 - Kod till boken finns [här](#)
 - Sample chapters
- Dataset till vissa uppgifter finns [här](#).

Notera att ni inte behöver göra alla delar på alla uppgifter. Det viktiga är att ni får en förståelse för de olika principerna och modellerna som avhandlats. Dessa uppgifter ska inte lämnas in, utan är till för er övning.

Datauppdelning

För att motverka överanpassning bör ni dela upp data till träning-, validering-, (och testmängd). Detta kan göras med `createDataPartition()` från `caret`-paketet. Argument till den funktionen som är av vikt här är p som hur stor andel av observationerna som ska användas till träningsmängden. Ni kan också använda `subset()` för att göra detta också, men det blir svårare att tydligt ange de observationer som ska tilldelas till valideringsmängden. Denna uppdelning ska ske slumpmässigt. Notera att om en testmängd ska skapas måste uppdelningen ske en gång till från valideringsmängden.

Del 0: Kod

- Klustering i Kodmanualen
- ISL se R-kod för kaptiel 12
- IDM, kod för klustering
- Från föreläsning 9: 2D-data och 3D-data
- Från föreläsning 10: [länk](#)

Del 1: K-means klustering och PAM

1. Gör lab 12.5.3 "K-means clustering" i **ISL**.
2. **ISL**: 12.6 Exercises Conceptual: 3
3. I denna kod: gå igenom 7.1 och 7.2.1
4. I denna kod: gå igenom 7.2.4 "Partitioning Around Medoids (PAM)"

Del 2: Startcentroider i K-means klustering

Använd "data1_alt.csv" för att beräkna en K-means klusteranalys. Data finns här.

1. Visualisera datamaterialet för att se med blotta ögat de kluster som finns där. Hur ser de naturliga klustrena ut? Var är deras centroider?
2. Genomför en k-means klustering med de angivna startcentroiderna i koden nedan samt ange antalet maximala iterationer till 1. Visualisera de resulterande klustren och tolka resultatet.

```
> cluster_result <- kmeans(x = data1,  
+                           centers = rbind(c(0,0), c(1, 0), c(-1, 0), c(1, 1)),  
+                           iter.max = 1, nstart = 1)
```

3. Öka antalet iterationer till något rimligt värde som tillåter algoritmen att konvergera och kör algoritmen igen och repetera steg 2. Blev resultatet något bättre? Varför inte?
4. Ange nu k slumpmässiga centroider istället. Tillåt algoritmen konvergera och jämför resultatet med steg 2. och 3.
5. Återkoppla till vilken funktion som K-means avser att optimera och bedöm vilken av diagrammen som visar de "korrekta" klustren.
6. K-means++: Nu ska ni jämföra k-means++ med "vanliga" k-means, gå igenom koden här: kod

Del 3: Hierarkisk klustering

1. Gör lab 12.5.3 "Hierarchical Clustering" i ISL.
2. I denna kod: gå igenom 7.2.2
3. **ISL**: 12.6 Exercises Conceptual: 2
4. **ISL**: 12.6 Exercises Applied: 9

Del 3.1 Länkningsmetoder i hierarkisk klustering

Använd data2.csv för att göra hierarkisk klusteranalys.

1. Visualisera materialet i två dimensioner och definiera antalet naturliga kluster.
2. Beräkna en hierarkisk klustering med följande länkningsmetoder och visa lämpliga dendrogram:
 - (a) Enkel länkning
 - (b) Fullständig länkning
 - (c) Ward's metod
3. Definiera från varje dendrogram hur många kluster som hittats och visualisera resultatet i ett diagram. Verkar metoden ha hittat de naturliga klustren? Vilken länkningsmetod anser ni vara lämpligast för denna sorts data?
4. Genomför K-means klustering på samma data och jämför med resultaten med enkel länkning. Vilken egenskap från de två metoderna visas här?

Del 4: Densitetsbaserad klustering

- I denna kod: gå igenom 7.2.4 "Density-based clustering with DBSCAN"

Använd `data3.csv` för att beräkna densitetsbaserad klusteranalys.

1. Visualisera materialet i två dimensioner och definiera antalet naturliga kluster.
2. Genomför klustering med DBSCAN och följande värden: `eps = 0.18`, `minPts = 3` och `borderPoints = TRUE`. Vad innebär dessa inställningar? Visualisera de resulterande klustren och bedöm ifall de faller in med de naturliga klustren som identifierats tidigare.
3. Testa ändra på `eps` argumentet till mindre och större värden. Hitta det minsta värdet då alla observationer tilldelas till ett kluster. Beskriv hur förändringen av detta argument påverkar klusterresultatet, d.v.s. vad händer i algoritmen i och med förändringen.
4. Testa att ändra på `minPts`- och `borderPoints`-argumenten. Hur förändras de resulterande klustren?
5. Genomför k-means klustering med några olika värden på k . Visualisera de resulterande klustren och jämför med steg 2. Vilken av metoderna anses producera "bättre" resultat? Om resultaten skiljer sig åt, försök förklara varför.

Del 5 Utvärdera kluster

1. Utgå från koden i 7.5 Cluster Evaluation
2. Utgå från koden i 7.7 Outliers in Clustering

Del 6: Irisdata

Använd nu det inbyggda datasetet `iris`. Notera att här finns det tre klasser (Species). Använd inte den variabeln i klusteringen, utan endast de fyra numeriska variablerna.

1. Genomför klustering med DBSCAN. Välj valfria värden på hyperparametrarna. Hur många kluster erhåller ni? Undersök hur väl klustringen matchar de befintliga grupperna (klasserna).
 - (a) Gör parvisa punktdiagram för variablerna (blir sex stycken), låt klustren ha olika färger. Låt klasserna representeras av olika symboler. Hur blir uppdelningen?
 - (b) Om matchningen blir dålig: försök att ändra på hyperparametrarna för att få en bättre gruppering.
 - (c) Beräkna förväxlingsmatrisen mellan de skattade klustren och den sanna klasserna. Hur förhåller sig klasserna till de erhållna klustren?
2. Genomför klustering med k-means. Testa $k=2,3,4,5$. Undersök hur väl klustringen matchar de befintliga grupperna (klasserna).
 - (a) Gör parvisa punktdiagram för variablerna (blir sex stycken), låt klustren ha olika färger. Låt klasserna representeras av olika symboler. Hur blir uppdelningen?
 - (b) Beräkna förväxlingsmatrisen mellan de skattade klustren och den sanna klasserna. Hur förhåller sig klasserna till de erhållna klustren?
3. Genomför klustering med hierarkisk klustering. Testa minst två olika länkningsmetoder.
 - (a) Gör parvisa punktdiagram för variablerna (blir sex stycken), låt klustren ha olika färger. Låt klasserna representeras av olika symboler. Hur blir uppdelningen?
 - (b) Beräkna förväxlingsmatrisen mellan de skattade klustren och den sanna klasserna. Hur förhåller sig klasserna till de erhållna klustren?
4. Jämför resultatet i 1), 2) och 3). Vilken modell föredrar ni här?

Del 7: Teorifrågor

1. Ge ett exempel på ett datamaterial där k-means kommer att fungera dåligt.
2. Förklara varför man i K-means algoritmen beräknar centroidernas position genom ett medelvärde av alla klustrets punkter om vi använder det Euklidiska avståndsmåttet och vill minimera SSE.
3. Beskriv två alternativa lösningar till initialiseringsproblemen för val av startcentroider i K-means algoritmen utöver att slumpmässigt välja dessa.
4. Ge ett exempel på ett datamaterial som innehåller kluster av olika tätheter där DBSCAN inte kommer kunna hitta de "korrekta" naturliga klustren?
5. Vilka olika hyperparameterar finns det i
 - (a) k-means?
 - (b) DBSCAN?
 - (c) hierarkisk klustring?

Del 8: Mer klustering

Gå in på denna sida Clustering basic benchmark. Ni ska nu testa att klustra några dataset härifrån.

1. Ladda ner datasetet "Unbalance" och läs in i R.
 - (a) Plotta och undersök data
 - (b) Testa att göra klustra data med
 - i. k-means: testa olika värden på k
 - ii. DBSCAN: Välj valfria värden på hyperparametrarna.
 - iii. Hierarkisk klustring, välj valfri länkningsmetod.
 - (c) Hur fungerar klustringen i de olika fallen?
2. Ladda ner dataseteten "S-sets" och läs in i R.
 - (a) Börja med att undersöka data: Vad skiljer S1-S4 åt?
 - (b) Gå igenom dataseten S1-S4 och klustra med
 - i. k-means: testa olika värden på k
 - ii. DBSCAN: Välj valfria värden på hyperparametrarna.
 - iii. Hierarkisk klustring, välj valfri länkningsmetod.
 - (c) Hur fungerar klustringen i de olika fallen?

Del 9: Frivillig fördjupning

Principalkomponentanalys (PCA)

1. Kör lab 12.5.1 i **ISL**.
2. **ISL**: 12.6 Exercises Applied: 10