

732G57 Maskininlärning för statistiker

Föreläsning 1

Josef Wilzén

IDA, Linköping University, Sweden

- Introduktion
 - Kursupplägg
 - Introduktion till Maskininlärning
- Översikt av metoder
- Modellval och generalisering

- Lärare och examinator: Josef Wilzén, mail: josef.wilzen@liu.se
- Ny-ish kurs från 2025! Ersätter 732G12 Data-Mining
- Struktur: [Kurshemsidan](#), Lisam, Teams
- Kurslitteratur
- Upplägg:
 - Föreläsningar
 - Datorövningar/labbar
 - Projektarbete
 - Datortentamen

- Föreläsningar
 - Presenterar metoder, teori
- Datorövningar
 - Använd metoderna för att lösa övningar/problem
 - Förberedelse för projekt samt tentamen
- Projektarbete
 - Större uppgift där ni ska analysera eget datamaterial
 - Seminarie där man ska presentera och opponera
- Datortentamen
 - Påminner om datorövningar, kan ha något teoretiskt inslag
- Generativ AI/chatGPT

- Antal respondenter: 24
- Antal svar: 9 (38%)
- Helhetsbetyg: 4,11
- Förändringar till detta år:
 - Visa förändringar i övningsuppgifter/föreläsningar
 - Visa förändringar i projektet

- Möjligt att ha 2 bonuspoäng på tentamen.
- Krav: Delta aktivt på 10 av 15 datorlaborationer
- Delta aktivt innebär:
 - Vara på plats och jobba med kursen.
 - Ställa en fråga eller visa upp en lösning för läraren.
- Använda bonuspoängen:
 - Kan bara användas under de tre tillfällen kopplade till årets omgång.
 - Kan bara användas för att bli godkänd.

- Grupper om två.
- Gruppanmälan på Lisam.
- Eget datamaterial.
- Två steg:
 - Välja data, separat inlämning
 - Själva projektet: skriftlig och muntlig redovisning

Grov tidsplan:

- Vecka 37: Anmälan till grupper
- Vecka 38: Datainlämning
- Vecka 39 och framåt: Projektet - huvudsakligt arbete
- Vecka 43: Seminarium och inlämning av slutgiltig rapport

Vad behöver ni ha med er?

- Linjär algebra
- Matematisk analys
- Programmering
- Regression
- Statistik teori

Introduktion - Inläarning och studieteknik

- Ni har eget ansvar för era studier
- **Inläarning kräver aktivt arbete!**
- Digitala distraktioner
- Halvfart → kursen tar ca 20 h / vecka
- Svårt att ta igen i slutet om man inte arbetar kontinuerligt under kursens gång.
- Gör upp en egen studieplan → uppdatera vid behov
- Många lär sig bra genom att studera med andra
- Viktigt att arbeta med övningsuppgifterna
- **Generativ AI**

Från SCB: Med statistik menas vetenskapen om metoder för insamling, bearbetning, redovisning och analys av data. Statistik är också den siffermässiga beskrivningen av en viss företeelse, till exempel i tabellform. Statistik har alltså två betydelser: dels metodiken eller processen, dels informationen eller själva produkten.

Statistisk modellering: Vad är det? Hur går det till?

Från Wikipedia: Det handlar om metoder för att med data "träna" datorer att upptäcka och "lära" sig regler för att lösa en uppgift, utan att datorerna har programmerats med regler för just den uppgiften.

Från Wikipedia: ... betecknar verktyg för att söka efter mönster, samband och trender i stora datamängder. Verktögen använder beräkningsmetoder för multivariat statistisk analys kombinerat med beräkningseffektiva algoritmer för maskininlärning och mönsterigenkänning hämtade från artificiell intelligens.


Sorta överlapp mellan maskininlärning och data mining.

- Maskininlärning, mest fokus på predikationer.
- Data mining, mer fokus på att utforska dataset och hitta samband.

"Statistical learning" $\approx$ Maskininlärning.

Analysprocessen

Från problem till insikt



Bilda grupper om 3 och diskutera er fram till två stora eller komplexa datamängder, beskriv vad det är för mängder och vilken information som kan finnas.

Exempel på stora/komplexa datamaterial



Tabellformat:

id	Variabel 1	Variabel 2	Variabel 3	...
1	.	.	.	...
2	.	.	.	...
3	.	.	.	...
⋮	⋮	⋮	⋮	⋮

- Rader är objekt, record, observation, transaktion etc.
- Kolumner är variabler, attribut, kovariat, feature etc.
- Skalan på variablerna: Nominell, Ordinal, Intervall/kvot
- Finns andra format, t.ex. tidsserier, texter, bilder, grafer etc.

Olika typer av dataset



Tabelldata

ID	Ålder	Kön	Inkomst	Utbildning	Region	...
1	34	♂	450 000	Kandidat	Stockholm	...
2	28	♀	320 000	Gymnasium	Göteborg	...
3	45	♂	550 000	Master	Malmö	...
4	52	♂	610 000	Doktor	Uppsala	...
5	23	♀	280 000	Gymnasium	Västerås	...
6	37	♂	470 000	Kandidat	Örebro	...
...	...	...	...	...	...	...




Bilddata



Nätverk / graf-data



Tidseriedata



Textdata

analys
modell
data
information
maskininlärning
text prediktion
 mönster kändande

Från rådata till användbar data

Förbehandling och explorativ analys



Saknade värden

ID	Ålder	Inkomst	Stad
1	34	45000	Stockholm
2	NA	32000	Göteborg
3	28	NA	Malmö
4	45	61000	NA
5	37	28000	Uppsala



Ta bort rader/kolumner



Imputera (medelvärde, median, modellbaserat, ...)



Förbearbeta data

Aggregering



Urval




Reducera dimensionalitet



Diskretisering



Variabelomvandling



Skalning



Explorativ analys / plottar

Histogram



Boxplot



Spridningsdiagram



Korrelationsmatris



Förstå data, hitta mönster, upptäck avvikelser



Rådata



Hantera saknade värden



Förbearbeta



Utforska och visualisera




Användbar data för modellering

Iterativ process – tillbaka vid behov

Från data till inferens och prediktion

En statistisk modelleringsprocess



Exempel: Linjär regression

Vi har respons $\mathbf{y}$ och förklarande variabler $\mathbf{X}$.

Vi antar ett linjärt samband mellan $\mathbf{y}$ och $\mathbf{X}$.

Deterministisk modell:

$$\mathbf{y} = \mathbf{X}\beta.$$

Stokastisk modell:

$$\mathbf{y} = \mathbf{X}\beta + \boldsymbol{\varepsilon}, \quad \boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma_{\varepsilon}^2).$$

Vi kan skatta parametrar med $\hat{\beta} = (\mathbf{X}^{\top}\mathbf{X})^{-1}\mathbf{X}^{\top}\mathbf{y}$

Inferens genom att konstruera test eller konfidensintervall

Predikation genom att beräkna respons $\hat{y}$ för nya värden $\mathbf{X}_{\text{test}}$.

- Supervised learning
 - Klassificering och regression
 - Varje observation består av en responvariabel och förklarande variabler
- Unsupervised learning
 - Ett antal variabler, men ingen responsvariabel
- Semisupervised learning
 - Värdet på responsvariabeln finns bara på en delmängd av observationerna
- Reinforcement learning
 - Handlar om att lära sig agera optimalt i en miljö.
 - Använda data för att lära sig ett beteende.

- Supervised learning:
 - Prediktera morgondagens elpris
 - Identifiera objekt i en bild
 - Skapa en beskrivande text från en bild
- Unsupervised learning:
 - Identifiera köpmönster
 - Hitta liknande grupper av läkemedelsmolekyler
 - Hitta bedragare bland bankkunder

- Modellering
- Klassificering
- Regression
- Klusteranalys

Att välja en lämplig modell

För en lämplig modell gäller:

- Modellen ska fånga upp den relevanta strukturen i problemet och kunna svara på frågeställningen!
- Modellen ska vara så enkel som möjligt.
- Modellen ska gå att beräkna i rimlig tid.
- Vi vill att modellen ska **generalisera** till ny liknande data.

Att välja en lämplig modell - Exempel

Standardmodell med additivt brus:

$$y = f(x|\omega) + \varepsilon, \quad \mathbb{E}[\varepsilon] = 0, \quad \mathbb{V}[\varepsilon] = \sigma_\varepsilon^2.$$

- f är en okänd funktion
- ω är parametrar till f
- ε är slumpmässig felterm
- Exempel på funktioner:


$$f(x|\omega) = \omega_1 \cdot x + \omega_2$$

$$f(x|\omega) = \omega_3 \cdot \sin(2\pi\omega_1 x + \omega_2) + \omega_4$$

$$f(x|\omega) = \exp(-\omega_1(x - \omega_2)^2)$$

$$f(x|\omega) = \omega_1 x_1 + \omega_2 x_2 + \omega_3 x_3$$

Vilken modell är lämplig?



- Underanpassning: Modellen fångar inte upp relevanta strukturer i problemet.
- Överanpassning: Modellen fångar upp bruset i datan.

- För att hjälpa oss i modellval definierar vi en förlustfunktion/kostnadsfunktion
 - Givet data ger kostnadsfunktionen ett värde på hur bra modellen anpassar datan.
- Vanliga exempel:
 - Mean squared error (MSE)

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - f(x_i | \hat{w}))^2$$

- Mean absolute error (MAE)

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - f(x_i | \hat{w})|$$

- Cross entropy loss
- Missclassification loss

Standardprocessen:

- Dela upp din data i slumpmässiga delar:
 - Träningsdata
 - Valideringsdata
 - Testdata
- Olika proportioner kan användas
 - $(\frac{1}{3}, \frac{1}{3}, \frac{1}{3})$
 - $(0.5, 0.25, 0.25)$
 - $(0.8, 0.1, 0.1)$
- Träningsdata bör inte vara minst.
- Notera: i många källor/på internet så används ofta "test data" för att beskriva valideringsdata. Dvs de använder "test data" för att välja den bästa modellen

Hur hittar vi bästa modellen?

Börja med att ta fram några kandidatfunktioner

M1(?,?)

M2(?,?,?)


M3(?,?,?,?,?)

Träning

Validering


Test

Använd träningsdata för att skatta parametrarna i modellerna.




Valideringsdata

Använd valideringsdata för att välja den bästa skattade funktionen utifrån lämplig felfunktion.



Vi kan iterera mellan att skatta med träningsdata och utvärdera på valideringsdata

Valideringsdata




Här är träningsdata svart och valideringsdata vit.

Testdata

Vi använder testdatan för att få en väntevärdesriktig skattning av felfunktionen på ny data → vi skattar testfelet

Vi bör *inte* ändra något på modellen när vi ska använda den på testdata. Varför?



Givet ett antal modeller görs följande för varje modell:

1. Ta bort en observation och anpassa modellen till återstående data.
2. Använd den anpassade modellen för att beräkna felet på den borttagna observationen.
3. Upprepa 1 och 2 för alla datapunkter. Beräkna genomsnittet för felfunktionen över alla observationer.

Välj modellen med lägs genomsnittlig felfunktion.

OBS! Om vi har n observationer måste vi anpassa varje modell n gånger.

Leave-one-out cross-validation

$$\begin{pmatrix} x_{11} & x_{21} & & x_{p1} & y_1 \\ x_{12} & x_{22} & & x_{p2} & y_2 \\ x_{1j} & x_{2j} & & x_{pj} & y_j \\ & & & & \\ & & & & \\ & & & & \\ x_{1n} & x_{2n} & & x_{pn} & y_n \end{pmatrix}$$

K-fold cross-validation

Dela upp datan i k olika block. Givet ett antal modeller görs följande för varje modell:

1. Ta bort ett block och anpassa modellen till återstående data.
2. Använd den anpassade modellen för att beräkna felet på de borttagna observationerna.
3. Upprepa 1 och 2 för alla block. Beräkna genomsnittet för felfunktionen över alla olika block.

Välj modellen med lägs genomsnittlig felfunktion.

OBS! Om vi har K block måste vi anpassa varje modell K gånger.

K-fold cross-validation

X_{11}	X_{21}	X_{p1}	y_1
$\cdot$	$\cdot$	$\cdot$	$\cdot$
X_{1K}	X_{2K}	X_{pK}	y_K
$\cdot$	$\cdot$	$\cdot$	$\cdot$
$X_{1,jK+1}$	$X_{2,jK+1}$	$X_{p,jK+1}$	y_{jK+1}
$\cdot$	$\cdot$	$\cdot$	$\cdot$
$X_{1,(j+1)K}$	$X_{2,(j+1)K}$	$X_{p,(j+1)K}$	$y_{(j+1)K}$
$\cdot$	$\cdot$	$\cdot$	$\cdot$
$X_{1,(m-1)K+1}$	$X_{2,(m-1)K+1}$	$X_{p,(m-1)K+1}$	$y_{(m-1)K+1}$
$\cdot$	$\cdot$	$\cdot$	$\cdot$
$X_{1,mK}$	$X_{2,mK}$	$X_{p,mK}$	$y_{p,mK}$

Bias, varians och brus

Givet en modell

$$y = f(x) + \varepsilon, \quad \mathbb{E}[\varepsilon] = 0, \quad \mathbb{V}[\varepsilon] = \sigma_\varepsilon^2$$

med skattad funktion $\hat{y} = \hat{f}(x_{\text{test}})$.

Om vi beräknar MSE får vi:


$$\mathbb{E} \left[\left(y_{\text{test}} - \hat{f}(x_{\text{test}}) \right)^2 \right] = \mathbb{V}[\varepsilon] + \mathbb{V} \left[\hat{f}(x_{\text{test}}) \right] + \text{Bias} \left[\hat{f}(x_{\text{test}}) \right]^2$$

- Brusvariansen $\mathbb{V}[\varepsilon]$: irreducibelt brus
- Modellens varians $\mathbb{V}[\hat{f}(x_{\text{test}})]$: hur mycket ändras $\hat{f}$ när vi byter dataset
- Modellens systematiska fel $\text{Bias}[\hat{f}(x_{\text{test}})]$: modelleringsfel i modellen

Bias-variance-trade-off

Vi vill ha:

- Låg bias och låg varians → en modell som generaliserar bra på ny liknande data!



- För vissa komplexa modeller: **Double descent** → testfelet minskar för att sedan öka, men för att sedan minska igen

