

732G57 Maskininlärning för statistiker

Föreläsning 2

Josef Wilzén

IDA, Linköping University, Sweden

- Modellval
- Klassificering: utvärdering
- Generaliserade linjära modeller
- Modellval för linjär regression

- Vi söker en modell som **generaliserar** väl.
 - Med generalisering menas att den ska fungera bra på ny data.
- En flexibel (komplex) modell har lättare att överanpassa.
- Vad är "komplexitet"?
 - Linjär modell: Antal variabler, interaktioner, transformationer etc
 - Splines: frihetsgrader
 - Neurala nätverk: Bredd och djup av modellen
 - Trädmodeller: Djupet/antal löv

Regularisering är ett sätt att motverka överanpassning.

- Idé att hindra modellen att bli för komplex.
- Regularisering $\approx$ "begränsning"
- Ger förhoppningsvis bättre generaliseringsfel.
- **Mycket viktigt tema inom maskininlärning**
- Görs på olika sätt för olika modeller.

Idén är att

Flexibel modell + regularisering = en bra modell

Kommer prata mer om detta senare.

Två klassiska problem är regression och klassificering.

- Regression: Prediktera en variabel y , oftast y kontinuerlig. Bruset ε är:
 - Vanligast är normalfördelat.
 - Alternativt, t-fördelning, Gamma, Log-normal,...
 - Kan också vara diskret, Poisson, Negativ binomial,...
- Fördelningen ger felfunktionen.
- Klassificering: y är kategorisk med 2 eller flera utfall:
 - Binär: logistisk/probit regression
 - Fler klasser: Multinomial logistisk/probit regression
 - Kommer diskutera fler metoder senare
 - Hur skapar vi en felfunktion? Utvärdering?

Logistisk regression

- Responsvariabeln antas vara Bernoullifördelad:

$$y_i \sim \text{Bernoulli}(p_i), \quad \mathbb{P}(y_i = 1) = p_i.$$

- Logitlänken kopplar sannolikheten till den linjära prediktorn:

$$\log \left(\frac{p_i}{1 - p_i} \right) = \mathbf{x}_i^\top \boldsymbol{\beta}.$$

- Detta ger

$$p_i = \frac{\exp(\mathbf{x}_i^\top \boldsymbol{\beta})}{1 + \exp(\mathbf{x}_i^\top \boldsymbol{\beta})}.$$

- Likelihoodfunktionen för oberoende observationer är

$$L(\boldsymbol{\beta}) = \prod_{i=1}^n p_i^{y_i} (1 - p_i)^{1-y_i}.$$

- Parametrarna skattas genom att maximera likelihoodfunktionen:

$$\hat{\boldsymbol{\beta}} = \arg \max_{\boldsymbol{\beta}} L(\boldsymbol{\beta}).$$

Skattning i logistisk regression

Parametrarna skattas genom att maximera log-likelihoodfunktionen:

$$\hat{\beta} = \arg \max_{\beta} \ell(\beta),$$

där

$$\ell(\beta) = \sum_{i=1}^n [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)],$$

och

$$p_i = \frac{\exp(\mathbf{x}_i^{\top} \beta)}{1 + \exp(\mathbf{x}_i^{\top} \beta)}.$$

Optimeringsalgoritmer formuleras ofta för minimering. Därför kan vi minimera den negativa log-likelihoodfunktionen:

$$-\ell(\beta) = -\sum_{i=1}^n [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)] .$$

Vanliga optimeringsmetoder:

- Gradient descent och varianter av gradient descent
- Newton–Raphsons metod → använder hessianen
- Fisher scoring → använder förväntade hessianen
- Iteratively Reweighted Least Squares (IRLS)

Logistisk regression i R

`glm(..., family = binomial)` använder iterativt viktade minsta kvadratmetoden (IRLS), vilket för logistisk regression motsvarar Fisher scoring.

Multinomial logistisk regression: data

Antag att responsvariabeln har tre klasser:

$$Y_i \in \{1, 2, 3\}, \quad K = 3,$$

och att vi har fyra förklarande variabler:

$$x_1, x_2, x_3, x_4.$$

För tre observationer kan designmatrisen, inklusive intercept, vara

$$X = \begin{pmatrix} 1 & 1 & 0 & 2 & -1 \\ 1 & 0 & 1 & 1 & 0 \\ 1 & 1 & 1 & 0 & 2 \end{pmatrix}.$$

- Första kolumnen motsvarar interceptet.
- Övriga kolumner motsvarar x_1, x_2, x_3, x_4 .
- Varje rad motsvarar en observation.

One-hot-kodning av responsvariabeln

Antag att de tre observationerna tillhör klasserna

$$\mathbf{y} = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix} \implies \mathbf{Y} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}.$$

Kolumnerna i $\mathbf{Y}$ motsvarar klasserna $k = 1, 2, 3$.

Elementen i den one-hot-kodade responsmatrisen definieras som

$$y_{ik} = \begin{cases} 1, & \text{om observation } i \text{ tillhör klass } k, \\ 0, & \text{annars.} \end{cases}$$

- Varje rad motsvarar en observation.
- Varje kolumn motsvarar en klass.
- Varje rad summerar till ett.

Referensklass-formulering

En vanlig formulering väljer en av de K klasserna som referensklass.

Om klass $k = 3$ är referensklass modelleras

$$\log \left(\frac{P(Y_i = 1 | \mathbf{x}_i)}{P(Y_i = 3 | \mathbf{x}_i)} \right) = \beta_{01} + \mathbf{x}_i^T \boldsymbol{\beta}_1,$$

och

$$\log \left(\frac{P(Y_i = 2 | \mathbf{x}_i)}{P(Y_i = 3 | \mathbf{x}_i)} \right) = \beta_{02} + \mathbf{x}_i^T \boldsymbol{\beta}_2.$$

- Endast $K - 1$ linjära prediktorer behöver skattas.
- Koefficienterna tolkas relativt referensklassen.
- Ett byte av referensklass ändrar koefficienterna, men inte modellens skattade klassannolikheter.

Softmax-formulering

En linjär prediktor används för varje klass:

$$\eta_{ik} = \beta_{0k} + \mathbf{x}_i^\top \boldsymbol{\beta}_k, \quad k = 1, \dots, K.$$

Klassannolikheterna beräknas med softmax-funktionen:

$$p_{ik} = P(Y_i = k \mid \mathbf{x}_i) = \frac{\exp(\eta_{ik})}{\sum_{j=1}^K \exp(\eta_{ij})}.$$

Softmax ger giltiga klassannolikheter:

$$0 < p_{ik} < 1, \quad \sum_{k=1}^K p_{ik} = 1.$$

I `glmnet` använd `family = "multinomial"` En koefficientvektor skattas för varje klass.

Exempel på skattade koefficienter

Antag att följande koefficientmatris har skattats:

		$k = 1$	$k = 2$	$k = 3$
$\hat{\Theta} =$	Intercept	0.4	-0.2	-0.2
	x_1	0.6	-0.3	-0.3
	x_2	-0.3	0.5	-0.2
	x_3	0.2	-0.4	0.2
	x_4	-0.1	0.1	0

Varje kolumn innehåller koefficienterna för en klass:

$$\tilde{\beta}_k = \begin{pmatrix} \beta_{0k} \\ \beta_{1k} \\ \vdots \\ \beta_{4k} \end{pmatrix}, \quad k = 1, 2, 3.$$

Exempel på skattade koefficienter

De linjära prediktorerna för observation i blir

$$\hat{\eta}_i = \hat{\Theta}^T \tilde{\mathbf{x}}_i, \quad \tilde{\mathbf{x}}_i = \begin{pmatrix} 1 & x_{i1} & x_{i2} & x_{i3} & x_{i4} \end{pmatrix}^T.$$

Beräkning av klassannolikheter

Betrakta en observation med

$$\tilde{\mathbf{x}}_i = \begin{pmatrix} 1 & 1 & 0 & 1 & 0 \end{pmatrix}^T.$$

De linjära prediktorerna beräknas som

$$\hat{\boldsymbol{\eta}}_i = \hat{\boldsymbol{\Theta}}^T \tilde{\mathbf{x}}_i = \begin{pmatrix} 1.2 \\ -0.9 \\ -0.3 \end{pmatrix}.$$

Softmax-funktionen ger

$$\hat{p}_{ik} = \frac{\exp(\hat{\eta}_{ik})}{\sum_{j=1}^3 \exp(\hat{\eta}_{ij})}.$$

För observation i får vi därför

$$\begin{pmatrix} \hat{p}_{i1} \\ \hat{p}_{i2} \\ \hat{p}_{i3} \end{pmatrix} = \frac{1}{e^{1.2} + e^{-0.9} + e^{-0.3}} \begin{pmatrix} e^{1.2} \\ e^{-0.9} \\ e^{-0.3} \end{pmatrix} \approx \begin{pmatrix} 0.743 \\ 0.091 \\ 0.166 \end{pmatrix}.$$

Modellen predikterar klass 1, eftersom

$$\hat{p}_{i1} = \max_{k \in \{1,2,3\}} \hat{p}_{ik}.$$

Hur påverkar koefficienterna prediktionen?

Varje klass k har en egen linjär prediktor:

$$\eta_{ik} = \beta_{0k} + \sum_{j=1}^p x_{ij} \beta_{jk}.$$

- En positiv β_{jk} innebär att ett större värde på x_j ökar den linjära prediktorn för klass k .
- En negativ β_{jk} innebär att ett större värde på x_j minskar den linjära prediktorn för klass k .
- Softmax jämför de linjära prediktorerna för alla klasser:

$$p_{ik} = \frac{\exp(\eta_{ik})}{\sum_{r=1}^K \exp(\eta_{ir})}.$$

- En klass med högre η_{ik} får en högre skattad sannolikhet relativt övriga klasser.

Hur påverkar koefficienterna prediktionen?

Predikterad klass

Observation i klassificeras till den klass som har högst skattad sannolikhet:

$$\hat{y}_i = \arg \max_{k \in \{1, \dots, K\}} \hat{p}_{ik}.$$

Log-likelihood

För observation i och klass k är

$$y_{ik} = \begin{cases} 1, & \text{om observation } i \text{ tillhör klass } k, \\ 0, & \text{annars.} \end{cases}$$

Likelihoodfunktionen är

$$L(\Theta) = \prod_{i=1}^n \prod_{k=1}^K p_{ik}^{y_{ik}}.$$

Log-likelihoodfunktionen blir

$$\ell(\Theta) = \sum_{i=1}^n \sum_{k=1}^K y_{ik} \log(p_{ik}).$$

Parametrarna skattas genom att maximera log-likelihooden:

$$\hat{\Theta} = \arg \max_{\Theta} \ell(\Theta).$$

One-hot-kodning

Varje observation bidrar endast med logaritmen av den skattade sannolikheten för observationens faktiska klass.

Förväxlingsmatris

		Predikterad klass	
		Class = 1	Class = 0
Sann klass	Class = 1	f_{11}	f_{10}
	Class = 0	f_{01}	f_{00}

- Träffsäkerhet:

$$T = \frac{f_{11} + f_{00}}{f_{11} + f_{10} + f_{01} + f_{00}}.$$

- Felkvot (error rate):

$$E = \frac{f_{10} + f_{01}}{f_{11} + f_{10} + f_{01} + f_{00}}.$$

- Obalanserade klasser? Olika typer av fel är olika allvarliga?

Förväxlingsmatris

		Predikterad klass	
		Class = 1	Class = 0
Sann klass	Class = 1	f_{11}	f_{10}
	Class = 0	f_{01}	f_{00}

- Sensitivitet (recall, hit rate, true positive rate):

$$\text{TPR} = \frac{f_{11}}{f_{11} + f_{10}}.$$

- Specificitet (selectivity, true negative rate):

$$\text{TNR} = \frac{f_{00}}{f_{00} + f_{01}}.$$

- Beräknas klassvis.

- Precision (positive predictive value):

$$\text{PPV} = \frac{f_{11}}{f_{11} + f_{01}}.$$

- F-score är ett mått av träffsäkerhet baserat på precision och sensitivitet.

$$F_{\beta} = (1 + \beta^2) \frac{\text{PPV} \cdot \text{TPR}}{\beta^2 \cdot \text{PPV} + \text{TPR}}$$

- Vanligt med $\beta = 1$ vilket ger (harmoniska medelvärde)

$$F_1 = 2 \frac{\text{PPV} \cdot \text{TPR}}{\text{PPV} + \text{TPR}}$$

- F-score är mellan 0 och 1, högre är bättre.
- β säger hur du värderar precision och sensitivitet.
- Beräknas klassvis.

- Vanligt att skatta modellen med en förlustfunktion (t.ex. negativ loglikelihoodfunktionen/cross entropy loss) och sedan utvärdera med andra mått (felkvot, sensitivitet, specificitet etc)
- Problemet och strukturen på data avgör vilka mått som är lämpliga
- Förväxlingsmatris - fler klasser, se separat dokument: [kommer snart](#)

Utgå ifrån: y kontinuerlig med normal likelihood.

Vi har ett antal förklarande variabler $\mathbf{x} = (x_1, \dots, x_p)$. Vill hitta parametrar/modell som ger minst generaliseringsfel.

Två alternativ:

- Alternativ 1: Välj ut en delmängd av variablerna.
 - Best subset, forward selection, backward selection
- Alternativ 2: Behåll alla variabler men begränsa parametrarna.
 - Regularisering, Ridge och Lasso.

Om vi har flera modeller, hur jämför vi dessa?

Två alternativ:

- Indirekt skatta testfelet
 - Utgå från träningsmängden
 - Försök att minska den bias som uppstår när vi inte använder all data.
- Direkt skatta testfelet
 - Valideringsdata
 - Korsvalidering

Indirekt skatta testfelet

MSE på träningsdatan underskattar "riktiga" MSE värdet, kan inte användas för att välja modell.

Idé: justera träningsfelet för att ta hänsyn till detta.

$$C_p = \frac{1}{n}(\text{RSS} + 2d\hat{\sigma}^2),$$

Litet C_p är bäst.

$$\text{adjusted } R^2 = 1 - \frac{\text{RSS} / (n - d - 1)}{\text{TSS} / (n - 1)},$$

där

$$\text{TSS} = \sum_{i=1}^n (y_i - \bar{y})^2.$$

Stort adjusted R^2 är bäst.

Tre andra mått AIC, BIC och HQIC är baserade på MLE skattning av modeller.

Låt $\log(\hat{L})$ vara log-likelihood för optimala parametervärden.

$$\text{AIC} = 2d - 2\log(\hat{L})$$

$$\text{BIC} = d \cdot \log(n) - 2\log(\hat{L})$$

$$\text{HQIC} = d \cdot \log(\log(n)) - 2\log(\hat{L})$$

Lågt värde är bättre.

Linjär Regression

$$\text{AIC} = \frac{1}{n\hat{\sigma}^2}(\text{RSS} + 2d\hat{\sigma}^2)$$

$$\text{BIC} = \frac{1}{n\hat{\sigma}^2}(\text{RSS} + \log(n)d\hat{\sigma}^2)$$

$$\text{HQIC} = \frac{1}{n\hat{\sigma}^2}(\text{RSS} + \log(\log(n))d\hat{\sigma}^2)$$

För linjär regression är $C_p \propto \text{AIC}$.

Algorithm 6.2 *Forward stepwise selection*

1. Let $\mathcal{M}_0$ denote the *null* model, which contains no predictors.
 2. For $k = 0, \dots, p - 1$:
 - (a) Consider all $p - k$ models that augment the predictors in $\mathcal{M}_k$ with one additional predictor.
 - (b) Choose the *best* among these $p - k$ models, and call it $\mathcal{M}_{k+1}$. Here *best* is defined as having smallest RSS or highest R^2 .
 3. Select a single best model from among $\mathcal{M}_0, \dots, \mathcal{M}_p$ using cross-validated prediction error, C_p (AIC), BIC, or adjusted R^2 .
-

Bild från kursboken "An Introduction to Statistical Learning with Applications in R".

Krympning (Shrinkage)

Idé: begränsa hur stora parametrarna får vara.

- Straffa stora parametrar
- Ändra deras värdemängd

Vanligaste metoderna:

- Ridge: l^2 -norm
- Lasso: l^1 -norm

Kom ihåg att standardisera era förklarande variabler först innan krympning!

Ridge Regression

I vanliga regression minimerar vi

$$f(\beta) = \text{RSS} = \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2$$

I Ridge lägger vi till l^2 -norm på β vilket ger

$$f_{\text{Ridge}}(\beta) = \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^p \beta_j^2, \quad \lambda \geq 0.$$

λ är en **hyperparameter** som vi behöver sätta.

Notera att β_0 inte påverkas.

Ridge Regression




FIGURE 6.4. The standardized ridge regression coefficients are displayed for the **Credit** data set, as a function of λ and $\|\hat{\beta}_\lambda^R\|_2 / \|\hat{\beta}\|_2$.

I vanliga regression minimerar vi

$$f(\beta) = \text{RSS} = \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2$$

I Ridge lägger vi till l^1 -norm på β vilket ger

$$f_{\text{Ridge}}(\beta) = \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^p |\beta_j|, \quad \lambda \geq 0.$$

λ är en **hyperparameter** som vi behöver sätta.

Notera att β_0 inte påverkas.

Lasso Regression




FIGURE 6.6. The standardized lasso coefficients on the **Credit** data set are shown as a function of λ and $\|\hat{\beta}_\lambda^L\|_1 / \|\hat{\beta}\|_1$.

Ridge vs Lasso

	Ridge	Lasso
$\lambda \rightarrow 0$	$\hat{\beta}_{\text{Ridge}} \rightarrow \hat{\beta}_{\text{OLS}}$	$\hat{\beta}_{\text{Lasso}} \rightarrow \hat{\beta}_{\text{OLS}}$
$\lambda \rightarrow \infty$	$\hat{\beta}_{\text{Ridge}} \rightarrow 0$	$\hat{\beta}_{\text{Lasso}} \rightarrow 0$
Norm	l^2 -norm	l^1 -norm
Område	Hypersfär	Polytop
Parametrar	Krymper och ger många små β	Sätter många till 0
Korrelerade variabler	Krymper alla lika mycket	Sätter en till 0

Ridge vs Lasso




FIGURE 6.7. Contours of the error and constraint functions for the lasso (left) and ridge regression (right). The solid blue areas are the constraint regions, $|\beta_1| + |\beta_2| \leq s$ and $\beta_1^2 + \beta_2^2 \leq s$, while the red ellipses are the contours of the RSS.

Ridge vs Lasso

- I R, skattas enkelt med `glmnet()` eller `cv.glmnet()`.
- Vilken som är bäst beror på kontext.
- Ridge passar bra när y beror på de flesta variablerna.
 - Många variabler och ungefär samma effektstorlek.
- Lasso passar bra när y beror på bara några få variabler.
 - Fåtal variabler med hög effektstorlek, resten nära 0.
- Lasso kan vara lättare att tolka.
- Vilken man ska välja får ofta avgöras empiriskt för specifika dataset.
- Finns många utökningar och varianter.
- l^2 -norm och l^1 -norm används som regularisering inom många olika modeller inom maskininlärning

- Låt varje parameter β_j ha sin egen vikt w_j

$$f(\beta) = \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^p w_j |\beta_j|, \quad \lambda \geq 0.$$

- Välj vikter

$$w_j = |\hat{\beta}_{j,\text{start}}|^{-\gamma}$$

- Ofta väljs $\gamma = 1$.
- Behöver startvärde $\hat{\beta}_{j,\text{start}}$, kan använda OLS eller Ridge skattning.
- Stora startvärden ger små vikter vilket gör att parametern krymper mindre.
- Finns vissa teoretiska fördelar, men kräver extra skattning.

Elasticnet regression

- Kombinerar Ridge och Lasso.
- Ny hyperparameter α för att mixa dessa,

$$f(\beta) = \text{RSS} + \lambda \left((1 - \alpha) \sum_{j=1}^p \beta_j^2 + \alpha \sum_{j=1}^p |\beta_j| \right), \quad \lambda \geq 0, 0 \leq \alpha \leq 1.$$

- λ är likt tidigare hur mycket regularisering vi gör.
- α väljer hur mycket vikt vid Ridge respektive Lasso.
- Kan tvinga vissa β till 0, men inte lika många som Lasso.
- Klarar av korrelerade/grupper av variabler bättre än Lasso.
- Nackdel är att vi har två hyperparametrar.

Adaptive Elasticnet regression

- Kombinerar Ridge, Lasso och vikter.
- Ny hyperparameter α för att mixa dessa,

$$f(\beta) = \text{RSS} + \lambda \sum_{j=1}^p w_j \left((1 - \alpha) \frac{1}{2} \beta_j^2 + \alpha |\beta_j| \right), \quad \lambda \geq 0, 0 \leq \alpha \leq 1.$$

- Välj vikter

$$w_j = |\hat{\beta}_{j,\text{start}}|^{-\gamma}$$

- Ofta väljs $\gamma = 1$.
- Behöver startvärde $\hat{\beta}_{j,\text{start}}$, kan använda OLS eller Ridge skattning.
- Två hyperparameterar: α och λ