

732G57 Maskininlärning för statistiker

Föreläsning 9

Josef Wilzén

IDA, Linköping University, Sweden

Dagens föreläsning: Klustering

- Introduktion
- K-means klustering
- Hierarkisk klustering

Projektet - [kurshemsidan](#)

Viktiga dokument att ha koll på:

- Generella instruktioner: [länk](#)
- Datahatering och modellering: [länk](#)
- Mallen, finns info i: [pdf](#) och [rmd](#)
- Datum och deadlines: [länk](#)

Kursvecka 7: Föreläsning 11

- Teama: Modellering, modellval, sammanfattning av kursen ⇒ Bra för projektet!

- Ööversvakad inlärning: Lära sig data utan responsvariabel!
- Flera olika algoritmer:
 - **Klusteranalys**
 - Associationsanalys
 - Sekventiella mönster
 - Dimensionality reduction techniques
 - PCA, Faktormodeller
 - Representation Learning
 - Ex: Autoencoder

Målet med klusteranalys är att dela upp datamaterialet i grupper (kluster) som är intressanta och/eller användbara.

Vi vet inte i förväg vilka grupper som kommer att bildas.

Ingen responsvariabel.

Om erhållna kluster är intressanta och/eller användbara beror på kontexten/problemet/området.

1. Hur många kluster finns det i bilden?



2. Kom på något område där klusteranalys kan vara användbart.

Klusteranalys

Ett "kluster" är inte entydigt definierat.



Tillämpningsområden:

- Biologi (toxonomi/gener)
- Informationssökning (Sökmotorer)
- Psykologi och medicin
- Kunddata
- Sociala medier/nätverk

- Klassificeringsmetoder som vi jobbat med tidigare är exempel på övervakad inlärning. Ger etiketter till nya objekt, utgår från originaldata som har etiketter.
- Klusteranalys är ett exempel på oövervakad inlärning - vi härleder en etikett för objekt, utgår endast från data.

Klustringstyper

Partitionell: Data är indelad i ett antal oöverlappande kluster.

Hierarkisk: Delkluster är tillåtna, kluster är representerade som ett träd.

Uteslutande: Ett objekt tillhör ett kluster.

Överlappande: Ett objekt hör till några kluster.

Fuzzy: Ett objekt hör till olika kluster med en specifik sannolikhet.


Fullständig: Varje objekt är tillskrivet (minst) ett kluster.

Ofullständigt: Vissa objekt är inte tillskrivna något kluster.


- Separerade
- Angränsande/intelliggande
- Centroid- eller prototypbaserade
- Densitet- eller täthetsbaserade
- Konceptuella




(a) Well-separated clusters. Each point is closer to all of the points in its cluster than to any point in another cluster.




(b) Center-based clusters. Each point is closer to the center of its cluster than to the center of any other cluster.




(c) Contiguity-based clusters. Each point is closer to at least one point in its cluster than to any point in another cluster.



(d) Density-based clusters. Clusters are regions of high density separated by regions of low density.



(e) Conceptual clusters. Points in a cluster share some general property that derives from the entire set of points. (Points in the intersection of the circles belong to both.)




K-means klustering

- Centroid-baserad och partionell klustringsmetod.
 - Centroid är en punkt som ska representera/sammanfatta alla observationer i ett kluster.
- Enkel och ofta effektiv metod.
- K : hyperparameter, antalet klasser.


Algorithm 8.1 Basic K-means algorithm.

- 1: Select K points as initial centroids.
 - 2: **repeat**
 - 3: Form K clusters by assigning each point to its closest centroid.
 - 4: Recompute the centroid of each cluster.
 - 5: **until** Centroids do not change.
-


K-means klustering: Exempel




(a) Iteration 1.



(b) Iteration 2.



(c) Iteration 3.



(d) Iteration 4.

K-means: Val av startvärden

K-means behöver K initiala centroider. Två klassiska metoder är:

- **Forgy-metoden:** Välj K distinkta observationer slumpmässigt som initiala centroider.
- **Slumpmässig indelning:** Tilldela varje observation slumpmässigt till ett av de K klustren och beräkna därefter centroiden för varje kluster.
- Forgy-metoden är vanligast i praktiken.
- `stats::kmeans(x, centers = K)` använder Forgy-metoden.
- Ofta används flera slumpmässiga starter, exempelvis `nstart = 50`.

K-means klustering: Slumpmässig indelning

Algorithm 10.1 *K-Means Clustering*

1. Randomly assign a number, from 1 to K , to each of the observations. These serve as initial cluster assignments for the observations.
 2. Iterate until the cluster assignments stop changing:
 - (a) For each of the K clusters, compute the cluster *centroid*. The k th cluster centroid is the vector of the p feature means for the observations in the k th cluster.
 - (b) Assign each observation to the cluster whose centroid is closest (where *closest* is defined using Euclidean distance).
-

Från An Introduction to Statistical Learning with Applications in R av
Gareth James, Daniela Witten, Trevor Hastie, Robert Tibshirani

K-means klustering: Exempel




FIGURE 10.6. The progress of the K-means algorithm on the example of Figure 10.5 with $K=3$. Top left: the observations are shown. Top center: in Step 1 of the algorithm, each observation is randomly assigned to a cluster. Top right: in Step 2(a), the cluster centroids are computed. These are shown as large colored disks. Initially the centroids are almost completely overlapping because the initial cluster assignments were chosen at random. Bottom left: in Step 2(b), each observation is assigned to the nearest centroid. Bottom center: Step 2(a) is once again performed, leading to new cluster centroids. Bottom right: the results obtained after ten iterations.

K-means klustring: Detaljer

- Låt c_i vara centroid för kluster i . Låt C_i vara en mängd med alla observationer i kluster i .
- Vi behöver ett avståndsmått
 - Används för att mäta avståndet mellan c_i och övriga observationer.
 - Vanligast är euklidiskt avstånd,

$$d(x, x') = \sqrt{\sum_{i=1}^p (x_i - x'_i)^2}$$

- Finns andra val som kan göras.

K-means klustering: Detaljer

- K-means minimerar SSE
- SSE i ett kluster ges av

$$E_{c_i} = \sum_{x \in C_i} d(x, c_i)^2.$$

- Totala SSE för alla kluster

$$\text{SSE} = \sum_{i=1}^K E_{c_i} = \sum_{i=1}^K \sum_{x \in C_i} d(x, c_i)^2$$

- I det euklidiska rummet beräknas centroider som

$$c_i = \frac{1}{n_i} \sum_{x \in C_i} x.$$


- K-means algoritmen hittar ett lokalt minima.

- 2D-data: faithful och geyser - [länk](#)
- 3D-data: palmerpenguins - [länk](#)

K-means klustring: Startvärden

Vi måste välja våra initiala gissningar för centroider. Detta val påverkar starkt utgången av algoritmen.

Dåliga startvärden kan ge dåliga resultat.



Vanlig metod är att köra algoritmen många gånger med olika (slumpade) startvärden.

- Algoritm som motverkar problemet med startvärden.
- Dela upp datamängden i två kluster, välj ett och dela upp det i två osv.
 - Valet av kluster kan göras med avseende på flest observation, störst SSE eller annat kriterie.
- Uppdelningen kan liknas vid ett binärt träd.


Bisecting K-means

Bisecting K-means skapar klustren stegvis:


1. Börja med alla observationer i ett enda kluster.
2. Välj ett befintligt kluster att dela.
 - Ofta väljs klustret med störst SSE.
3. Dela det valda klustret genom att köra K-means med $K = 2$.
4. Ersätt det gamla klustret med de två nya klustren.
5. Upprepa tills önskat antal kluster har skapats.

Till skillnad från vanlig K-means skapas inte alla K kluster samtidigt.

Halverande K-means



(a) Iteration 1.



(b) Iteration 2.



(c) Iteration 3.



Algorithm 8.2 Bisecting K-means algorithm.

- 1: Initialize the list of clusters to contain the cluster consisting of all points.
 - 2: **repeat**
 - 3: Remove a cluster from the list of clusters.
 - 4: {Perform several “trial” bisections of the chosen cluster.}
 - 5: **for** $i = 1$ to *number of trials* **do**
 - 6: Bisect the selected cluster using basic K-means.
 - 7: **end for**
 - 8: Select the two clusters from the bisection with the lowest total SSE.
 - 9: Add these two clusters to the list of clusters.
 - 10: **until** Until the list of clusters contains K clusters.
-

Algoritm för att hitta startvärden till K-means.

1. Välj en centroid uniformt slumpmässigt från observationerna.
2. För varje datapunkt x beräkna avståndet $d(x, c_i)$ mellan x och den närmaste centroiden (som redan valts).
3. Välj en datapunkt som centroid genom att:
 - Slumpa en punkt med hjälp av viktade sannolikheter, där vikterna är proportionella mot $d(x, c_i)^2$, där c_i är den närmaste centroiden för varje punkt.
4. Upprepa 2 och 3 tills K centroider valts ut.
5. Kör vanlig K-means med dessa startcentroider.

- Generellt: K-means++ förbättrar SSE mycket över slumpade startvärden.
- Tar extra tid att bestämma startvärden, men K-means konvergerar mycket snabbare än med slumpade startvärden.
- Vanligt att K-means++ är dubbelt så snabb som K-means med slumpade startvärden.

K-means klustering: Kommentarer

- Enkel och ganska effektiv.
- Känslig mot startvärden.
 - Kör många gånger med olika startvärden.
 - Halverande K-means.
 - K-means++
- Skapar klotformade kluster och är linjärt separerade.
 - Om datas "naturliga kluster" har andra former fungerar k-means sämre.
- Ger en centroid för varje kluster. Kan användas för att beskriva klustret.
- Har svårt att identifiera kluster av olika storlekar eller med olika tätheter.
- Känslig mot extremvärden.

Beräkningskomplexitet

Låt n vara antal observationer, p antal variabler, K antal kluster och I antal iterationer.

- **Vanlig K-means:**

$$\mathcal{O}(npKI)$$

- **K-means++:**

$$\mathcal{O}(npK) + \mathcal{O}(npKI)$$

Dyrare initialisering, men ofta snabbare konvergens.

- **Bisecting K-means:**

$$\mathcal{O}(npl \log K)$$

Ofta snabbare än vanlig K-means när K är stort.

Antalet omstarter multiplicerar beräkningskostnaden.

Utökningar av K-means

K-means kan generaliseras genom att byta närhetsmått och anpassa klusterrepresentanten.

- **Kvadrerat euklidiskt avstånd**

$$d(x, c)^2 = \sum_{j=1}^p (x_j - c_j)^2$$

Klusterrepresentant: komponentvisa **medelvärden**.

- **Manhattanavstånd (L_1)**

$$d(x, c) = \sum_{j=1}^p |x_j - c_j|$$

Klusterrepresentant: komponentvisa **medianer** (*K-medians*).

- **Cosinusavstånd**

$$d(x, c) = 1 - \frac{x^\top c}{\|x\| \|c\|}$$

Klusterrepresentant: **normaliserat medelvärde** (*spherical K-means*).

K-medians är en robust variant av K-means.

- Använder **Manhattanavstånd** (L_1):

$$d(x, c_k) = \sum_{j=1}^p |x_j - c_{kj}|.$$

- Varje kluster representeras av den komponentvisa **medianen**:

$$c_{kj} = \text{median}\{x_{ij} : x_i \in C_k\}.$$

- Algoritmen upprepar två steg:
 1. Tilldela varje observation till det närmaste klustercentrumet (med Manhattanavstånd).
 2. Uppdatera klustercentrumen genom att beräkna komponentvisa medianer inom varje kluster.
- Mindre känslig för extremvärden än vanlig K-means.
- Kan fortfarande konvergera till ett lokalt optimum och bör därför köras med flera startvärden.

K-means med cosinusavstånd

K-means med cosinusavstånd kallas ofta **spherical K-means**.

- Observationerna normaliseras till längd 1:

$$\tilde{x}_i = \frac{x_i}{\|x_i\|}.$$

- Klustertillhörighet bestäms med cosinusavstånd:

$$d(x, c_k) = 1 - \frac{x^\top c_k}{\|x\| \|c_k\|}.$$

- Varje observation tilldelas det klustercentrum som ger minst cosinusavstånd.
- Klustercentrumet beräknas som klustrets medelvärde och normaliseras därefter till längd 1.

Spherical K-means: Tillämpningar

Spherical K-means grupperar observationer efter **riktning** snarare än efter vektorernas storlek.

- **Dokumentklustering:** ordindikatorer, ordfrekvenser
- **Högdimensionella och glesa data:** många variabler men relativt få värden skilda från noll.
- **Vektorinbäddningar:** exempelvis representationer av text eller bilder.
- **Asymmetriska binära data:** när gemensamma ettor är informativa men gemensamma nollor inte ska påverka likheten.

Metoden är särskilt användbar när vektorernas riktning är viktigare än deras längd.


Utökningar av K-means

- Kernel K-means: Kan forma kluster av olika former med icke-linjära separationsgränser.
- Gaussian mixture models/klustring:
 - Varje kluster beskrivs med en multivariat normalfördelning.
 - Skattas med expectation-maximization (EM) algoritmen.
- K-medoids/Partitioning Around Medoids (PAM). Använder medioder som center (en punkt i datasetet).


- Två typer:
 - Agglomerativ, bygger underifrån.
 - Diversiv, bygger uppifrån.
- Skapar en hierarki med kluster.
 - Subkluster som har subkluster som har subkluster....

Agglomerativ hierarkisk klustring


- Börja med att ge varje observation sitt egna kluster. Slå ihop närliggande kluster till ett större kluster. Upprepa detta tills alla observationer är i ett kluster.
- Processen visualiseras i ett s.k. dendrogram.
 - Vågrät axel innehåller observationsnummer (ordningen är godtycklig)
 - Lodrät axel mäter avstånd mellan kluster.
 - Förgreningen mäter vilka kluster och vid vilket avstånd dessa slås ihop.



Agglomerativ hierarkisk klustering



(a) Dendrogram.



(b) Nested cluster diagram.

Figure 7.13. A hierarchical clustering of four points shown as a dendrogram and as nested clusters.

- Dendogrammet visar **alla** ihopslagningar.
- Vi måste manuellt ange när vi anser att ihopslagningarna ska sluta:
Hur många kluster?
 - Subjektivt
 - När avståndet mellan ihopslagningar är "stort nog".
- Svårt att visualisera om vi har många observationer

Dendrogram




FIGURE 12.11. Left: dendrogram obtained from hierarchically clustering the data from Figure 12.10 with complete linkage and Euclidean distance. Center: the dendrogram from the left-hand panel, cut at a height of nine (indicated by the dashed line). This cut results in two distinct clusters, shown in different colors. Right: the dendrogram from the left-hand panel, now cut at a height of five. This cut results in three distinct clusters, shown in different colors. Note that the colors were not used in clustering, but are simply used for display purposes in this figure.

Algorithm 7.4 Basic agglomerative hierarchical clustering algorithm.

- 1: Compute the proximity matrix, if necessary.
 - 2: **repeat**
 - 3: Merge the closest two clusters.
 - 4: Update the proximity matrix to reflect the proximity between the new cluster and the original clusters.
 - 5: **until** Only one cluster remains.
-

Proximity matrix är en matris som innehåller närheten mellan kluster.
Kan använda en distansmatris också.

Närhetsmått vid hierarkisk klustering

Vid agglomerativ hierarkisk klustering behöver vi göra två val:

1. Avstånd mellan observationer

- Euklidiskt avstånd
- Manhattanavstånd
- Cosinus- eller korrelationsavstånd
- Gower-avstånd för blandade datatyper

2. Avstånd mellan kluster (länkningsmetod)

- Single linkage
- Complete linkage
- Average linkage
- Ward's metod

Både avståndsmåttet och länkningsmetoden kan påverka vilka kluster som skapas.

Beräkning av avstånd mellan två kluster

Då kluster ofta innehåller flera observationer behövs en metod för att definiera hur avstånd beräknas, även kallad **länkningsmetod**.

Låt C_i och C_j vara två kluster.

- MIN eller Single linkage (enkel länkning):

$$\text{prox}(C_i, C_j) = \min_{x \in C_i, y \in C_j} \text{dist}(x, y).$$

- MAX eller Complete linkage (fullständig länkning):

$$\text{prox}(C_i, C_j) = \max_{x \in C_i, y \in C_j} \text{dist}(x, y).$$

Beräkning av avstånd mellan två kluster


- Group average (genomsnitts länkning):

$$\text{prox}(C_i, C_j) = \frac{1}{n_i \cdot n_j} \sum_{x \in C_i, y \in C_j} \text{dist}(x, y),$$


där n_i och n_j är antalet observationer i kluster i och j .

- Wards/Centroid metod: Närheten defineras som hur mycket kvadrerade fel ökar när två kluster slås ihop.
Samma kostnadsfunktion som i K-means.


Beräkning av avstånd mellan två kluster



(a) MIN (single link).



(b) MAX (complete link).



(c) Group average.

- Ingen global funktion att optimera.
- Group average- och olika centroid metoder kan ta hänsyn till olika klusterstorlekar när ett par kluster förenas.
- Ihopslagningar är slutgiltiga och går inte att ta isär senare.
- Närhetsmättet kan påverka resultatet.
 - Extremvärden.
 - Brus.
- Passar bra för data som har en hierarkisk struktur.

- 2D-data: faithful och geyser - [länk](#)

Exempel




Figure 7.15. Set of six two-dimensional points.

Point	<i>x</i> Coordinate	<i>y</i> Coordinate
p1	0.4005	0.5306
p2	0.2148	0.3854
p3	0.3457	0.3156
p4	0.2652	0.1875
p5	0.0789	0.4139
p6	0.4548	0.3022

Table 7.3. *xy*-coordinates of six points.

	p1	p2	p3	p4	p5	p6
p1	0.00	0.24	0.22	0.37	0.34	0.23
p2	0.24	0.00	0.15	0.20	0.14	0.25
p3	0.22	0.15	0.00	0.15	0.28	0.11
p4	0.37	0.20	0.15	0.00	0.29	0.22
p5	0.34	0.14	0.28	0.29	0.00	0.39
p6	0.23	0.25	0.11	0.22	0.39	0.00

Table 7.4. Euclidean distance matrix for six points.

Exempel




Figure 7.16. Single link clustering of the six points shown in Figure 7.15.






Figure 7.17. Complete link clustering of the six points shown in Figure 7.15.

Se förklaringar i kap. 5.3.2 i IDM

Exempel




(a) Group average clustering.




(b) Group average dendrogram.

Figure 7.18. Group average clustering of the six points shown in Figure 7.15.



(a) Ward's clustering.



(b) Ward's dendrogram.

Figure 7.19. Ward's clustering of the six points shown in Figure 7.15.