

Projekt – Modellering

Intro

Nedan följer några råd/rekommendationer hur man kan tänka kring datahantering och modellering när man arbetar med maskininlärning.

Data

- Se till att förstå era variabler. Beskriv tydligt vad som är era förklarande variabler och vad som är er responsvariabel. Beskriv tydligt vad som är en observation i ert dataset.
- Vid behov: Om ni har kategoriska variabler som är obalanserade överväg att slå ihop kategorier (om det är rimligt), detta gäller både reponsvariabeln och förklarande variabler.
- Eventuellt: undersök univariata extremvärden och överväg om enstaka observationer bör uteslutas från vidare analys. Bör göras med försiktighet.
- Hantera saknade värden:
 - Oftast så är det enklast att utesluta de observationer som har saknade värden
 - Ibland är det rimligt bra att använda någon sorts imputering. Man bör bara försiktig då en dålig imputering kan påverka vidare modellering negativt.
- Dela in data i tränings-, validerings- och testdata.
- Vid klassificering: undersök att förhållandet mellan andelen i era klasser är ungefär samma i de olika dataseten som ni delat upp i. Det är ok att det är variationer, men man vill undvika stora avvikelser och att någon klass helt saknas i något av dessa dataset.
- Lägg testdata åt sidan till slutet när modelleringen är klar. Testdata används när vi valt en slutgiltig modell och vill skatta den modellens generaliserbarhet på ny liknande data
- Vid behov standardisera variabler som är kontinuerliga. Spara `x_mean_train` och `x_sd_train` för alla variabler som standardiseras.
 - Standardisera valideringsdata och testdata vid behov baserat på `x_mean_train` och `x_sd_train` för motsvarande variabler.
- Ibland kan det vara ok att först dela upp i tränings och testdata, och sen standardisera träningsdata. Efter det så delar man upp i träningsdata och valideringsdata. Detta kan ibland vara motiverat om man använder ett nästlat valideringsschema (se nedan under Valideringsdata).
- Gör visualiseringar och beskrivande statistik baserat på träningsdata.

- Om outliers hittas eller andra problematiska observationer hittas: om ni vill utesluta vissa observationer, så till att sätta upp tydliga regler för vad som är en outlier. Dessa regler kan senare användas på valideringsdata eller testdata vid behov. Det viktiga är dessa regler ska baseras på träningsdata och att man inte ändrar dessa senare.
- Man ska dock vara försiktig med att utesluta observationer från data. Ibland kan problem ovanliga/extrema observationer hanteras med kostnadsfunktioner som kan hantera sådana värden. Tex använda MAE istället för MSE kan vara ibland lämpligt om det finns extrema värden i ens kontinuerlig responsvariabel.
- Vid behov: Gör lämpliga transformationer av variablerna i träningsdata. Dessa bör motiveras utifrån kunskap från träningsdata. Sen gör ni motsvarande transformationer i valideringsdata och testdata innan ni ska använda dessa. Notera dock om att era valda transformationer använder information från variablerna själva så kan ni ta den informationen från motsvarande variabel i träningsdata.
 - Exempel 1: Variabel x_8 log-transformeras i träningsdata $x8_log = \log(x_8)$. Gör på samma sätt i valideringsdata och träningsdata. (Inget speciellt i detta fall.)
 - Exempel 2: Variabel x_4 är kontinuerlig och ni har bestämt att den ska bli en kategorisk variabel med två klasser. Ni gör uppdelning i klasser baserat på om värdena är större än medianen av x_4 eller ej. Låt oss kalla det värdet för $x4_median_train$. När ni ska göra motsvarande transformation av x_4 i valideringsdata och testdata, använd då $x4_median_train$ för att göra uppdelningen.

Modellering – Skatta och utvärdera modeller

Ni ska beskriva era "praktiska metod": hur ni applicerar era metoder/modeller på ert problem. Ni ska alltså ha ett strukturerat arbetssätt och ni ska beskriva det övergripande här under Metoddelen i rapporten. Sen under Resultat visar ni resultatet av er applicerade metod.

- När man analyserar data är det naturligt att ha en initial fas där man explorativt utforskar data och olika metoder kopplat till problemet. Denna fas behöver man oftast inte skriva om under Metod. Notera: denna fas ska vara relativt kort i tid.
- Sen när ni fått ungefärlig bild av vad som ni behöver göras för att analysera er frågeställning så ska ni bestämma ett strukturerat upplägg på hur ni ska använda era metoder/modeller på ert problem.
- Hur ska data delas upp? (träning, validering, korsvalidering, test) Man bör ha tänkt på det innan, men ibland behöver man göra justeringar.

- **Vilka modeller/hyperparametrar/inställningar ska användas/göras? Detta är ofta en svår och viktig fråga.**
- Ofta behöver man fixera några inställningar/hyperparametrar (pga man behöver avgränsa arbetat och pga tidsbegränsningar)
- Andra inställningar/hyperparametrar vill man hitta så optimala värden för som möjligt (ofta med hjälp av korsvalidering/valideringsdata).
 - Kolla i litteraturen vilka hyperparameter som verkar vara mer viktiga för specifika modeller, dessa vill vi hitta bra värden på.
- Ange tydligt vilka hyperparametrar som ni fixerar och vilka som ni vill försöker optimera för olika metoder/modeller. De som ni optimerar: ange tydligt vilka olika hyperparametervärden som ni väljer mellan för varje specifik hyperparameter.
 - Exempel: "För KNN används korsvalidering med tio uppdelningar för att bestämma k . Följande värden på k testas: $k = 5, 7, 9, \dots, 25$. Det k som ger minst genomsnittligt MSE i korsvalideringen används."
- Om man ska göra en hyperparametersökning och behöver skatta många modeller, då är det ofta smidigt att koda det som en loop, där man loopar över olika hyperparametervärden. I loopen så sparar man lämpliga resultat för träning och validering i tex en vektor eller matris. Gör man detta så kan man skatta förhållandevis många modeller utan för mycket arbete. Sen är det enkelt att ta fram resultat för alla modeller man skattat och jämföra.
- Hur ska metoder/modellerna ska utvärderas och jämföras? Vilka utvärderingsmått? Plottar?
 - Klassificering: Här vill man kolla på övergripande mått och klassvisa mer detaljerade mått.
 - Regression: Här vill man kolla på övergripande mått och sen göra lämplig residualanalys
 - Olika mått/plottar för att avgöra effekten av olika förklarande variabler (då det är relevant)
 - Ofta är det bra med tydliga tabeller där man presenterar mått för olika modeller på träningsdata och valideringsdata.
- När ni utvärderar era modeller på valideringsdata så kan man använda plottar av valideringsdata vid behov. Om vi vill göra plottar på testdata så gör man det i samband med att testdata används på slutet.
- Notera: om ni ska göra korsvalidering så används träningsdata.
- Det är ok att revidera sitt praktiska upplägg vid behov efter att man har börjat med själva analysen (se till att uppdatera beskrivningen av upplägget)

Se nedan för olika sätt att använda **valideringsdata för modellval**.

Modellering – modellval och validering

Det finns två tydliga strategier när vi ska göra modellval/hyperparameterval med hjälp av valideringsdata. Antag att vi har gjort en uppdelning av data i träning, validering och test.

Kortfattat så kan vi illustrera det som:

- Modellval med **direkt** validering:
Träning → Validering → Test
- Modellval med **hierarkisk** validering:
Träning → Intern validering → Extern validering → Test

Låt oss beteckna:

- **Utvecklingsdata** = träning + all validering
- **Modelltyp**: En grupp eller familj med modeller, exempel kan vara: CART, neurala nätverk, Splines, KNN etc. Typiskt finns det många hyperparametrar inom varje modelltyp, vilket ger upphov till en stor mängd möjliga modeller.

Direkt validering använder samma valideringsmängd för både hyperparameterval och val av modelltyp. Hierarkisk validering separerar dessa beslut genom att använda olika valideringsmängder för de två stegen. Detta kan minska risken att modellvalet påverkas av slumpvariation som uppstått i en enskild valideringsmängd.

Modellval med direkt validering är det vanligaste upplägget och fungerar ofta bra när antalet modellkandidater är måttligt. Hierarkisk validering kan vara motiverad när många hyperparameterkombinationer undersöks per modelltyp och/eller vi har tillgång till mycket data.

Notera att i båda fallen så vill vi träna om den slutgiltigt valda modellen med **all** utvecklingsdata innan den sista utvärderingen med testdata görs. Orsaken är att modellvalet nu är avslutat och hyperparametrarna är låsta. Genom att använda all tillgänglig utvecklingsdata kan modellens parametrar skattas med mer information, vilket ofta leder till bättre generalisering.

Nedan så förtydligas arbetsgången för de två olika sätten.

Modellval med direkt validering:

- Dela upp data i mängderna: träning, validering och test.
- Använd träningmängden för att skatta olika kandidatmodeller.
- Använd valideringsdata för att jämföra olika kandidatmodeller och välja modelltyp och tillhörande hyperparametrar.
- Träna om den valda modellen på utvecklingsdata (träningsdata + valideringsdata).
- Utvärdera den slutliga modellen på testdata.

Modellval med hierarkisk validering:

- Dela upp data i mängderna: träning, validering och test. Denna valideringsmängd blir vår **externa** valideringsmängd.
- För varje modelltyp → Skapa **intern** träning och **intern** validering genom att dela upp träningsmängden.
 - intern träningsmängd används för att skatta olika kandidatmodeller inom modelltypen
 - intern valideringsmängd används för att välja hyperparametrar inom modelltypen
 - Notera: det är även möjligt att göra intern korsvalidering baserat på träningsmängden.
- Den externa valideringsmängden används för att välja mellan de bästa modellerna från respektive modelltyp.
- När modellvalet är avslutat samlas all utvecklingsdata (träning + interna valideringsmängder + extern validering)
- Den slutliga modellen tränas därefter om på all tillgänglig data utom testmängden.
- Testmängden används för den slutliga utvärderingen.

Skillnaden mellan direkt validering och hierarkisk validering ligger främst i hur modellvalet genomförs. I båda fallen är det vanligt att den slutliga modellen tränas om på all data som använts under modellutvecklingen (all data utom testmängden) innan den slutliga testutvärderingen genomförs.

Fördelar och nackdelar

Direkt validering

- Enkel att genomföra och lätt att förstå.
- Mer data kan användas för träning och validering i varje steg, vilket ofta ger stabilare modellval när datamängden är begränsad.
- Samma valideringsmängd används för både hyperparameterval och val av modelltyp, vilket kan ge en viss selektionsbias (optimism) i valideringsresultaten.

Hierarkisk validering

- Separerar hyperparameterval och val av modelltyp genom att använda olika valideringsmängder.
- Kan minska risken att modellvalet påverkas av slumpvariation i en enskild valideringsmängd och därmed minska selektionsbias.
- Kräver att data delas upp i fler delmängder, vilket innebär att varje beslut baseras på mindre data. Detta kan ge större variation i resultaten och mindre stabila modellval om datamängden är liten.

Tumregel

Direkt validering är ofta ett bra val när datamängden är begränsad och antalet modellkandidater är måttligt.

Hierarkisk validering blir mer attraktiv när datamängden är tillräckligt stor för att flera valideringsmängder ska kunna användas utan att varje delmängd blir för liten, särskilt om många kandidatmodeller jämförs.

Exempel där direkt validering kan vara lämpligt

Antag att vi har ett klassificeringsproblem med 2 000 observationer.

Uppdelning:

- Träning: 1 200 observationer
- Validering: 400 observationer
- Test: 400 observationer

Kandidatmodeller:

- CART: 10 hyperparameterkombinationer
- Neurala nätverk: 10 hyperparameterkombinationer

Totalt jämförs:

- 20 kandidatmodeller

Arbetsgång:

- Samtliga 20 modeller tränas på träningsdata.
- Valideringsdata används för att välja den bästa modellen.
- Den valda modellen tränas om på 1 600 observationer (träning + validering).
- Testmängden används för slutlig utvärdering.

Kommentar: Antalet kandidatmodeller är relativt litet och datamängden är inte särskilt stor. Det kan därför vara mer värdefullt att använda en större valideringsmängd än att dela upp data ytterligare för hierarkisk validering.

Exempel där hierarkisk validering kan vara lämpligt

Antag att vi har ett klassificeringsproblem med 100 000 observationer.

Yttre uppdelning:

- Träning: 60 000 observationer
- Extern validering: 20 000 observationer
- Test: 20 000 observationer

Intern uppdelning av träningsdata:

- Intern träning: 48 000 observationer
- Intern validering: 12 000 observationer

Kandidatmodeller:

- XGBoost: 200 hyperparameterkombinationer
- Neurala nätverk: 500 hyperparameterkombinationer

Totalt jämförs:

- 700 kandidatmodeller

Arbetsgång:

- Inom XGBoost jämförs 200 modeller med hjälp av intern validering.
- Inom neurala nätverk jämförs 500 modeller med hjälp av intern validering.
- Den bästa XGBoost-modellen och den bästa NN-modellen jämförs på den externa valideringsmängden.
- Den vinnande modellen tränas om på 80 000 observationer (all utvecklingsdata).
- Testmängden används för slutlig utvärdering.

Kommentar: Här jämförs många kandidatmodeller. Genom att separera hyperparameterval och val av modelltyp minskar risken att modellvalet påverkas av slumpmässiga variationer i en enda valideringsmängd. Kostnaden är att varje beslut baseras på mindre datamängder, men detta är oftast inget stort problem när datasetet är mycket stort.