

Projekt i Maskininläring för statistiker 732G57

Josef Wilzén

September 7, 2026

1 Lärandemål

Det huvudsakliga målet med denna inlämningsuppgift är att använda den teoretiska och praktiska kunskap som övats upp under första delen av kursen. Ni förväntas även få en praktisk övning i hur man kan analysera verkliga datamaterial samt de problem som kan uppstå med dessa. Det ingår även en övning i muntlig och skriftlig redovisning av analysresultatet. Instruktioner om vad som gäller kring generativ AI finns i sektion 4.

2 Instruktioner

Er uppgift är att i par välja ett datamaterial som ni ska analysera. Se Sektion 3 för detaljer. När ni väl har valt ett datamaterial ska ni komma på en frågeställning som kan besvaras genom att analysera det valda datamaterialet. Det huvudsakliga problemet i projektet ska behandla övervakad inläring. Det är dock tillåtet att använda oövervakad inläring som del i att analysera det huvudsakliga problemet. I analysen ska minst en modell vara ett neuralt nätverk.

Exempel på frågeställningar:

- Vilka egenskaper påverkar hurvida en komponent är trasig?
- Vilken modell ger bäst predikation av framtida inkomst?
- Vilken metod predikterar temperaturen bäst med avseende på MSE och MAE?

Under arbetets gång kommer ni säkert stöta på problem som till exempel att datamaterialet inte har det format som ni använt tidigare eller att en viss tilltänkt metod inte fungerar alls på det specifika datamaterialet. En del av denna inlämningsuppgift är att ni självständigt ska lösa dessa problem, men ni kan självklart ställa frågor under de schemalagda undervisningspassen. Lösningar som ni kommer på måste tydligt presenteras i rapporten som ni skriver för att uppfylla kravet om reproducerbarhet som råder för akademiska rapporter.

När ni väl kommit fram till ett svar på frågeställningen ska allting sammanställas i en rapport som ska formas enligt rapportmallen. Rapportmallen finns här och här (se även kurshemsidan), och innehåller instruktioner om hur ni ska skriva er rapport. Huvudfokus ligger på databeskrivningen och dess bearbetning samt rapportens metodkapitel. Alla analyser och slutsatser ska vara motiverade med lämpliga gradet och tabeller.

Rapporten ska skrivas med någon av följande programvaror:

- Rmarkdown¹ (med knitr) Rekommenderas för detta projekt!
- LaTeX Vanligt vid skrivandet av akademiska rapporter. Kan använda Overleaf för att skriva tillsammans online (utan strul med installationer).
- LyX Grafiskt program som generar en LaTeX-rapport i bakgrunden. Kan användas med knitr för att köra R-kod.

Om ni använder knitr med Rmarkdown/latex/lyx, då rekommenderas det att ni har separata R-filer där ni har era analyser, och att ni sen bara läser in lämpliga resultat i er rapport-fil. Så man inte måste köra om alla skattningar etc varje gång som man ska kompilera sin rapport-fil.

Rapporten ska lämnas in som en pdf-fil. Döp filen på formen **gruppX_liuid1_liuid2.pdf** och ladda upp i rätt mapp på samarbetsytan på Lisam. Er rapport ska vara snygg och välstrukturerad. Se rapportmallen för mer instruktioner.

¹Det går även att använda Quarto om man vill.

Tidigare studier

En del datamaterial har analyserats av andra och olika analyser kan finnas tillgängliga på internet. Det är inte ok att direkt kopiera någon annans analys av samma datamaterial. Det är ok att använda vissa avgränsade delar av andras analyser om tydligt anger vad man använt och citerar källan. Exempel kan vara att man använder samma transformation av förklarande variabler som i en annan analys. Man kan hämta inspiration av vilka metoder som har använts eller inte använts på just ert datamaterial. Om ni läser om andra analyser av ert datamaterial så bör ni skriva kort om dessa i er bakgrundsektion i rapporten (och citera!), alltså vad som har gjorts tidigare på ”området”.

Det är också ok att jämföra era egna resultat med resultatet från någon annans analys (glöm inte att citera då). Exempel: Ni har valt att använda neurala nätverk, ni ser att någon annan har använt random forest på samma data. Då kan ni i diskussionen citera den andra källan och jämföra era träffsäkerhet med deras träffsäkerhet. Det är inte ok att ta någon annas resultat från modellskattningar som ert eget resultat, utan ni måste skatta alla era egna modeller själv.

Datainlämning

Ni ska göra en mindre inlämning på Lisam innan ni lämnar in den färdiga rapporten. Där ska ni:

- Beskriva vilket datamaterial som ni har valt.
 - Vilka variabler, antal variabler, antal observationer osv.
 - Vilken variabel är er responsvariabel? Vid klassificering: Undersök klassbalansen för klasserna.
 - Kortfattad explorativ analys: kortfattad beskrivande statistik av data och/eller några plottar av data.
- Ange preliminär frågeställning (ok att ändra senare vid behov).

Inlämningen ska vara en pdf-fil som är 2-3 sidor lång. Syftet är att ni ska välja data och komma igång med inledande datahantering, och börja fundera över frågeställningen. Det är ok att återanvända hela eller delar av denna inlämning till den slutgiltiga rapporten om man vill.

Presentation

Under seminariet kommer det ges 25 minuter till varje grupp. Under de första 15 minuterna ska ni presentera och sammanfatta den rapport som ni gjort, övriga 10 minuter lämnas för opponering från opponentsgruppen. Alla gruppmedlemmar ska vara aktiva under presentationen.

Riktlinjer:

- Ni ska beskriva ert problem och ert dataset tydligt. Förklara er datahantering.
- Metod: Ni behöver inte förklara all teori kring de metoder/modeller som ni har valt. ²
 - Undantag: Om ni har använt någon metod som ligger utanför det som kursmaterialet har tagit upp, då behöver ni beskriva den metoden kortfattat så att andra som läser kursen kan förstå grunderna i metoden. Undvik att förklaringen tar lång tid.
 - Förklara kort vilka metoder/modeller som ni har valt. Förklara kort varför metoderna valdes. **Förklara er praktiska metod** och hur ni har tänkt kring modellering, hyperparametrar och utvärdering.
- Presentera era resultat, diskussion och slutsatser. Se till att svara på er frågeställning.
- Presentera på slutet hur ni har använt generativ AI i projektet, och resonera kring det i relation till er inlämning. Ha minst en slide om det.
- Se till att hålla tiden.

Ladda upp era slides (som pdf) för presentationen på samarbetsytan i kursrummet **innan** seminariet.

Opponering

Varje grupp ska opponera på en annan grupp. Det förväntas att fokus ligger på det statistiska, det vill säga hur metoderna presenteras, används och tolkas.

- Vid den muntliga opponeringen så ska de större konceptuella frågorna och kommentarerna tas upp.

²Historiskt så har det varit grupper som lagt ner mycket tid på att förklara teori kring metoder och inte hunnit prata om resultat etc.

- Det är **inte ok** bara säga något i stil med ”allt var bra gjort”. Försök att (konstruktivt) kritisera arbetet. Det är ok att kritisera delar som ni ”håller med om” (detta kan man göra för att testa att de förstår sitt arbete). Den muntliga opponeringen ska ta 7-10 min, så se till ha frågor/diskussion som fyller den tiden. ³
- **Ni måste ha minst två frågor som kritiserar gruppens metod, och som kräver att respondenterna utvecklar sitt resonemang.**
- Börja med de viktigaste/största frågorna när ni opponerar.
- Svara inte själva på era frågor, utan ge respondenterna tid att svara.
- Alla gruppmedlemmar ska vara aktiva under den muntliga opponeringen.
- Mindre kommentarer och saker som rör formalia tas bara upp skriftligt.

Varje grupp ska sammanställa sina kommentarer i ett dokument som sedan ska skickas till rapportgruppen och lärare. Detta dokument ska innehålla både de små och stora kommentarerna.

3 Datamaterial

Varje grupp ska välja ett eget datamaterial. Två grupper kan inte ha samma datamaterial och först till kvarn gäller. På Lisam under sammarbetsyta finns ett excelark där ni kan skriva upp vilket datamaterial ni valt. Kom ihåg att citera källan på ert datamaterial i er rapport.

Välja datamaterial

Ni är fria att välja ett eget datamaterial. Följande regler gäller:

- Inget datamaterial som ni har arbetet med under datorlaborationerna under kursen.
- Inget simulerat datamaterial eller ”toy data”. Det ska vara ett riktigt datamaterial som kan användas för en riktig frågeställning.
- Inte för ”enkelt”: Tumregel, minst 3000 observationer eller minst förklarande 50 variabler. Ni måste ha minst 4 förklarande variabler som är numeriska eller heltalsvärda ⁴. Fråga om ni är osäkra.
- När ni hittat ett datamaterial, skriv upp det i dokumentet. Fråga lärare om ni är osäkra på valet.
- Problemet ska vara inom **övervakad inlärning** (kan vara antingen regression eller klassificering).
- Ni får **inte** ta något datamaterial som användes på projektet tidigare år, här finns de listade: [länk](#)

Ni väljer själva var ni vill hämta data ifrån. Här kommer några förslag på datakällor:

- Machine Learning Repository
- Kaggle datasets
- MedMNIST
- Datasets for Data Mining, Data Science, and Machine Learning
- Awesome Public Datasets
- List of datasets for machine-learning research
- Kan också använda databaser från pxweb, se också här och här.

³Om ni är osäkra på tiden så kan ni förbreda fler frågor än vad som kanske kommer att hinnas med, och så kör ni så många frågor som ni hinner under utsatt tid.

⁴Notera: Heltalsvärda, ej kategoriska variabler som kodas med heltal.

4 Användning av generativ AI under projektet

Det är tillåtet att använda generativ AI för att underlätta er egen inläring av kursens material, alltså använda det på ett sätt som ökar er kunskap och förståelse för kursinnehållet samt ger stöd för ert lärande. Det går bra att bolla idéer och få feedback på sitt arbete med en generativ AI.

Ni får inte ta text skriven av en generativ AI rakt av in i ert rapport. Om ni får hjälp av en generativ AI på någon del i arbetet så behöver ni skriva om det med egna ord.

Det är inte tillåtet att:

- Skriva hela eller delar av rapporten med generativ AI.
- Låta generativ AI ta fram all eller den mesta av den kod som används i projektet
- Ladda in er data direkt i en generativ AI och låta den skatta era modeller eller ta fram era plottar/tabeller. Det är ok att få hjälp med kod som kan skapa t.ex. plottar.
- Låta generativ bestämma allt eller merparten av er ”praktiska metod”⁵ i projektet.

Om ni använder generativ AI

Under Metod skriv ner vilka system för generativ AI som ni använt när ni listar vilka programvaror ni använt i arbetet.

I bilagan finns en rubrik ”Generativ AI” här skriver ni mer detaljerat hur ni gått tillväga med att använda generativ AI i ert arbete, se nedan.

Om ni inte använt generativ AI så skriver ni bara något i stil med ”Generativ AI har inte används som hjälpmedel i detta arbete.” under rubriken ”Generativ AI” i bilagan.

Struktur

- Generellt: skriv mer allmänt hur ni använde generativ AI i arbetet
- Sektion per sektion: För varje sektion så ska ni ange på vilket sätt generativ AI användes, och övergripande förklara arbetsprocessen i relation till generativ AI.

På **presentationen** så ska ni berätta hur ni har använt generativ AI och göra en reflektion kring detta i relation till ert lärande.

Ni behöver inte redovisa varje prompt/anrop som ni gjort till en generativ AI, utan beskriv mer övergripande vad ni har gjort. Fokusera på arbetsprocessen. Om ni använder kod från generativ AI, som t.ex. är med i bilagan, ange då källan till koden.

Notera: generativ AI kan generera svar som är falska eller inkorrekta på olika sätt. T.ex. så kan referenser skapas som inte finns i verkligheten. Kolla alltid upp källan om ni får tips på en referens av en AI. Ni har ansvar för att ert arbete är korrekt och håller en bra kvalitet. Kolla upp i andra traditionella källor vid behov. Ni är ansvariga för det som står i ert arbete.

Alla gruppdeltagare ska vara beredda att muntligen förklara alla delar av ert arbete, för att visa att ni har förståelse för och kunskap om det som ni har gjort i arbetet. Vid behov kan ni bli kallade till extra möte med lärare för att muntligen diskutera ert arbete.

Se till att använda generativ AI ansvarsfullt.

⁵För detaljer kring er praktiska metod, se rmd-mallen och dokumentet 'Projekt modellering' ”